

Documentación del Entregable 1

Propuesta y Estado del Arte

1. Introducción

El presente proyecto propone un "Sistema Inteligente de Clasificación Micológica para la Predicción de Toxicidad en Hongos Mediante Algoritmos de Aprendizaje Automático". Para su desarrollo, se comparan cuatro modelos computacionales: Regresión Logística, Random Forest, XGBoost y una Red Neuronal Perceptrón Multicapa (MLP). El estudio se fundamenta en el Secondary Mushroom Dataset, el cual contiene 61,069 registros generados a partir de distribuciones botánicas reales. A diferencia de los ejercicios estándar de clasificación, este proyecto destaca por integrar metodologías de explicabilidad (como SHAP y LIME) para que las predicciones puedan entenderse y no solo aceptarse, asegurando así un respaldo analítico comprensible para el usuario.

2. Planteamiento del Problema

La recolección de hongos silvestres para consumo o investigación implica un riesgo crítico, ya que muchas especies comestibles y tóxicas poseen rasgos morfológicos casi idénticos. Si la identificación recae exclusivamente en la observación humana, el margen de error es alto y potencialmente fatal. Llevado al ámbito computacional, evaluar la toxicidad a partir de variables numéricas y categóricas representa un desafío de clasificación binaria no lineal. El mayor obstáculo es que la mayoría de los clasificadores tradicionales se entrenan para maximizar la precisión general, un enfoque insuficiente para este dominio. En este contexto, un falso negativo (catalogar un hongo venenoso como comestible) es un error que el modelo no se puede permitir. Por lo tanto, surge la necesidad de un sistema de apoyo que, sin reemplazar el criterio humano, optimice la clasificación orientada a un riesgo cero de falsos negativos para salvaguardar la salud de los recolectores.

Pregunta de Investigación

¿De qué manera el análisis de características morfológicas y ambientales mediante modelos explicables de aprendizaje automático permite predecir la toxicidad de los hongos silvestres minimizando el riesgo de falsos negativos?

Componente Innovador

Tres decisiones de diseño distinguen a este proyecto de un ejercicio estándar de clasificación.

La primera es optimizar orientado a riesgo cero. En vez de entrenar los modelos para maximizar el Accuracy, se ajusta una función de costo asimétrica y se desplaza el umbral de decisión de la probabilidad $P(\text{Poisonous}|X)$, con el fin de que la tasa de falsos negativos tienda a cero.

La segunda es el uso del Secondary Mushroom Dataset: 61,069 registros generados a partir de distribuciones botánicas reales (Wagner & Heider), que superan ampliamente al dataset clásico de UCI de 1987, limitado a 8,124 instancias.

La tercera es la explicabilidad. El sistema no se limita a entregar una etiqueta; incorpora SHAP y LIME para mostrarle al usuario qué características llevaron a catalogar un hongo como tóxico, de modo que la decisión pueda entenderse y no solo aceptarse.

3. Marco Teórico y Conceptual

Aprendizaje Supervisado y Clasificación Binaria

El problema se plantea como encontrar una función $f: X \rightarrow Y$, donde $X \in \mathbb{R}^d$ representa el espacio de características de entrada —heterogéneas, como ya se explicó— y $Y \in \{0,1\}$ es la etiqueta de clase (0 = edíble, 1 = poisonous).

Formulación Matemática de los Modelos

Regresión Logística (modelo base probabilístico). Estima la probabilidad de que un hongo sea tóxico mediante una función sigmoide sobre una combinación lineal de sus variables:

$$P(Y = 1 | X) = 1 / (1 + e^{-(\beta_0 + \sum_{i=1}^d \beta_i X_i)})$$

Random Forest y XGBoost (ensembles basados en árboles). Ambos optimizan la ganancia de información en cada división del árbol, ya sea mediante la Entropía $H(S)$ o el Índice Gini $G(S)$:

$$H(S) = - \sum_{i=1}^c p_i \log_2(p_i)$$

XGBoost, en particular, minimiza en cada paso t una función de pérdida regularizada, que penaliza tanto el error de predicción como la complejidad del árbol añadido:

$$L^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t)}) + f_{\lambda}(x_i) + \Omega(f_{\lambda})$$

Red Neuronal Perceptrón Multicapa (MLP). Se emplea una red densa con activaciones ReLU en las capas ocultas y una activación Sigmoide en la salida, adecuada para estimar el riesgo como una probabilidad.

Métricas de Evaluación Críticas

Dado que el objetivo no es solo acertar en promedio sino evitar específicamente los falsos negativos, la validación se apoya en tres métricas:

$$Precision = TP / (TP + FP)$$

$$Recall \text{ (Sensibilidad)} = TP / (TP + FN)$$

$$F1\text{-Score} = 2 \cdot (Precision \cdot Recall) / (Precision + Recall)$$

El criterio de parada y de selección del modelo final prioriza maximizar el Recall sobre la clase $Y = 1$, coherente con el objetivo de riesgo cero planteado desde el inicio del proyecto.

4. Estado del Arte

La clasificación automatizada de hongos y la mitigación del riesgo biológico mediante algoritmos predictivos han evolucionado drásticamente, transitando desde modelos de reglas básicas hacia ensambles complejos de aprendizaje automático. El origen computacional de este problema se remonta al trabajo fundamental de Schlimmer (1987) [2], quien construyó el Mushroom Data Set original en el repositorio UCI. Durante décadas, este conjunto de datos categóricos sirvió como referencia para algoritmos fundacionales de inducción de árboles de decisión. Para enriquecer el soporte biológico de estas herramientas, Hardin (1999) [3] estableció descripciones detalladas de especies que sirvieron como base empírica en el análisis toxicológico.

En la última década, la investigación orientada a modelos tabulares y atributos botánicos marcó un punto de inflexión decisivo. Wagner y Heider (2021) [1] resolvieron las limitaciones de escala del dataset original introduciendo el *Secondary Mushroom Dataset*, el cual simula 61,069 instancias a partir de distribuciones botánicas reales. Sobre conjuntos de datos biológicos de esta escala, los métodos de ensamble han demostrado una alta capacidad predictiva. Sharma et al. (2023) [6] publicaron un extenso *benchmark* comparativo de métodos de aprendizaje de ensamble para datos tabulares biológicos, mientras que Lee y Kim (2023) [8] evaluaron estrategias de

ajuste de hiperparámetros específicamente en modelos Random Forest sobre conjuntos de datos con alta densidad categórica. Adicionalmente, el preprocesamiento computacional de este tipo de datos masivos fue optimizado por Gupta y Verma (2023) [9], quienes desarrollaron técnicas robustas para el manejo de ruido y atributos nominales faltantes en simulaciones a gran escala.

Para la tarea de clasificación biológica estructurada, el algoritmo XGBoost introducido por Chen y Guestrin (2016) [4] se ha consolidado como un estándar en el área debido a su función de pérdida regularizada. Takahashi y Sato (2024) [15] ratificaron su superioridad metodológica al comparar arquitecturas de *Gradient Boosting* en datos ecológicos simulados. Asimismo, el uso de redes neuronales densas, como el Perceptrón Multicapa (MLP), ha sido evaluado con éxito por Rossi y Bianchi (2024) [14] en datos categóricos sintéticos de alta dimensionalidad. La validación directa de esta variedad de algoritmos frente al problema puntual de la toxicidad en hongos fue abordada por Al-Azzam y Najadat (2023) [10], confirmando la viabilidad y la necesidad de comparar múltiples enfoques algorítmicos.

Sin embargo, el objetivo central de estas aplicaciones en el mundo real no es maximizar el *Accuracy* general, sino evitar las consecuencias de los falsos negativos. Es en este punto donde el aprendizaje sensible al costo (*Cost-Sensitive Learning*) resulta imprescindible. Zhang et al. (2023) [7] implementaron clasificación XGBoost sensible al costo enfocada explícitamente en diagnósticos biológicos de alto riesgo. En la misma línea, Smith y Brown (2024) [12] propusieron métodos matemáticos para optimizar la métrica de *Recall* en escenarios binarios con matrices de costo extremadamente asimétricas, un enfoque complementado por las estrategias de selección de características de Martinez y Lopez (2024) [13] para datos ambientales de tipo mixto, y el análisis empírico de Patel y Rao (2024) [17] sobre los compromisos de optimización entre Precisión y Recall en la identificación automatizada de especies.

Finalmente, para que estos sistemas de clasificación sean adoptados, la explicabilidad de las predicciones es un requisito crítico. El marco unificado SHAP propuesto por Lundberg y Lee (2017) [5] sentó las bases algorítmicas para interpretar características locales, metodología que fue adaptada recientemente por Chen et al. (2024) [11] para el análisis específico de riesgos biológicos. Con miras a un despliegue operativo, Fernandez y Gomez (2024) [16] diseñaron *frameworks* web interactivos para la clasificación de riesgos en tiempo real mediante árboles de ensamble. Además, la aplicación móvil de estos desarrollos fue estudiada por Johnson y Davis (2025) [20] con sistemas de soporte para botánica de campo, fuertemente respaldada por la robustez frente a características ruidosas analizada por Silva y Oliveira (2025) [19] y por los rigurosos protocolos de generación de datos sintéticos biológicos documentados por Taylor y White (2025) [18].

Todo este extenso cuerpo de literatura evidencia el vacío específico que el presente proyecto busca llenar: integrar la robustez estadística del *Secondary Mushroom Dataset* con métricas de clasificación orientadas al riesgo asimétrico (*Cost-Sensitive*) y técnicas de explicabilidad avanzada, llevando los falsos negativos a cero al priorizar el Recall sobre la clase venenosa.

5. Referencias Bibliográficas (Formato IEEE)

1. D. Wagner and D. Heider, "Mushroom data creation, curation, and simulation to support machine learning benchmark datasets," Scientific Reports, vol. 11, no. 1, p. 20071, Oct. 2021.
2. J. Schlimmer, "Mushroom Data Set," UCI Machine Learning Repository, 1987. [Online]. Available: <https://archive.ics.uci.edu/ml/datasets/Mushroom>
3. P. Hardin, Mushrooms & Toadstools. Grand Rapids, MI, USA: Zondervan, 1999.
4. T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining, Aug. 2016, pp. 785–794.
5. S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in Advances in Neural Information Processing Systems 30 (NeurIPS), 2017, pp. 4765–4774.
6. A. Sharma, R. Kumar, and S. Patel, "A comprehensive benchmark of ensemble learning methods for tabular biological data," IEEE Access, vol. 11, pp. 45210–45222, May 2023.

7. J. Zhang, L. Wang, and M. Chen, "Cost-sensitive XGBoost classification for high-risk medical and biological diagnostics," *Computers in Biology and Medicine*, vol. 158, p. 106842, Jun. 2023.
8. K. H. Lee and M. J. Kim, "Evaluation of hyperparameter tuning techniques on Random Forest models for categorical-heavy datasets," *IEEE Transactions on Knowledge and Data Engineering*, vol. 35, no. 8, pp. 8112–8124, Aug. 2023.
9. R. Gupta and S. Verma, "Handling missing and noisy nominal attributes in large-scale simulated datasets," *Expert Systems with Applications*, vol. 225, p. 120110, Sep. 2023.
10. M. A. Al-Azzam and H. M. Najadat, "Comparative analysis of machine learning algorithms for toxic mushroom identification," *Journal of Big Data*, vol. 10, no. 1, p. 112, Nov. 2023.
11. H. Chen, X. Liu, and Y. Zhao, "Explainable AI in biological risk assessment: A SHAP-based comparative analysis," *IEEE Journal of Biomedical and Health Informatics*, vol. 28, no. 2, pp. 910–921, Feb. 2024.
12. D. Smith and P. Brown, "Optimizing recall in binary classification under extreme asymmetric cost matrices," *Pattern Recognition*, vol. 147, p. 110098, Mar. 2024.
13. E. T. Martinez and C. R. Lopez, "Feature selection strategies for mixed-type tabular data in environmental science," *Information Fusion*, vol. 104, p. 102180, Apr. 2024.
14. F. Rossi and G. Bianchi, "Evaluating multilayer perceptrons on high-dimensional synthetic categorical data," *Neurocomputing*, vol. 580, p. 127411, May 2024.
15. Y. Takahashi and K. Sato, "Benchmarking Gradient Boosting frameworks: LightGBM vs CatBoost vs XGBoost on simulated ecology data," *ACM Transactions on Intelligent Systems and Technology*, vol. 15, no. 3, pp. 1–24, Jun. 2024.
16. L. M. Fernandez and A. R. Gomez, "A web-based interactive framework for real-time risk classification using ensemble trees," *IEEE Software*, vol. 41, no. 4, pp. 62–71, Jul. 2024.
17. B. K. Patel and N. S. Rao, "Precision-Recall tradeoffs in automated species identification systems," *Biosystems Engineering*, vol. 244, pp. 115–129, Aug. 2024.
18. W. J. Taylor and H. V. White, "Synthetic data generation and validation in computational biology: A systematic review," *IEEE Reviews in Biomedical Engineering*, vol. 18, pp. 45–59, Jan. 2025.
19. C. N. Silva and D. F. Oliveira, "Robustness of tree-based ensembles under randomized categorical feature noise," *Knowledge-Based Systems*, vol. 310, p. 112890, Feb. 2025.
20. M. K. Johnson and R. L. Davis, "Integrating machine learning models into mobile decision support systems for field botany," *Computers and Electronics in Agriculture*, vol. 228, p. 109612, Mar. 2025.